单块注意力的权重与网格联合前沿

第五阶段研究指南 2026 年 11 月 2 日

这一阶段把此前平方根网格上的权重阈值，推进为整个权重与网格平面的风险定理。对固定三符号及以上字母表，单个全局汇总块中的两项资源不能完全替代：网格分辨率仍必须达到抽样尺度，而权重放大与网格的乘积共同控制稀少末尾上下文的误差。这个结论同时适用于平稳初始化与任意初始化。[TR001]

本指南面向熟悉概率与渐近分析的读者。先把模型、风险和资源口径固定，再解释新的网格下界为何不怕极大的权重。最后讨论二符号的结构改进：它不是把三符号证明里的常数改成 2，而需要新的活跃马尔可夫链下界与加权回返上界。[UI001；BI001 v2；BU001 v2]

先固定预测对象和信息边界

观察未知齐次二阶源的 $X_1,\dots,X_{M+2}$，预测真实末尾对 (X_{M+1},X_{M+2}) 的下一符号分布。风险是同一条轨迹上的无条件期望总变差，不是把查询独立抽样后得到的风险。符号对转移核与隐藏平稳律满足

$$P^2(s,t)\ge\beta\,\Pi(t),0\le\beta\le1.$$

这个条件覆盖所有起点和终点，包括平稳支撑外的状态。β 是公开类承诺，Π 不是输入；证书不唯一时，实验也包含证书的选择。平稳实验从 Π 出发，任意初始化实验则允许未知的任意初始对分布。

架构常数 D,r 固定，不随样本数、混合参数或预算增长。D 是保留的标量坐标数，不是物理头数；r 是局部窗口长度。给定边界符号 S，每个坐标只保留

$$B_d=\frac{\sum_{i=3}^{M+2}w_{di}v_{di}}{\sum_{i=3}^{M+2}w_{di}},Z_d=\frac{\lfloor QB_d\rfloor}{Q}.$$

实际权重在 $[1,\kappa]$，实际值满足 $|v_{di}|\le1$；表可以依赖位置、公开参数、各键位置的至多 r 个尾随局部符号及由 S 算出的查询，但必须源无关。所有键都以正权重进入比值。S 仅含首尾各至多 r 个符号，重叠必须一致。

译码器可以随机化并输出实数概率，但只读取量化库、允许的边界与公开信息。禁止额外精确计数、历史重读、查询选择的硬掩码、非局部内部特征或递归全局块。后文最优性始终限于这个族，不是一般 Transformer 的最优性。

三符号及以上的完整联合风险

固定 $K\ge 3$、$D\ge K^{3}$、$r\ge 3$，并取 $M\ge 64$、整数权重预算 $\kappa\ge 1$ 与二进网格 $Q=2^{h}$、整数 $h\ge 4$。定义

$$\beta_{0}=max(\beta,1/M),z=\kappa Q,t=M\beta_{0},$$

$$W(z,t)=\frac{1+\ln(1+z/t)}{z},F=max\{M^{-1/2},Q^{-1},W(z,t)\}.$$

TR001 给出在全部上述合法参数上的一致结论

$$cF\le R_{stat}\le R_{all}\le R(T_{SB})\le min\{1,CF\}.$$

$c>0$ 只依赖固定 D,r，C 只依赖固定 K，都不随 β,M,κ,Q 改变。它描述的是对编码器与译码器优化之后的极小极大风险，不是说每个合法编码器都达到此界。

三个项各有来源。$M^{-1/2}$ 是即使给出完整历史也无法消除的独立样本估计误差；Q^{-1} 是对任意有限权重范围一致成立的新网格障碍；W 来自稀少末尾活跃段在量化前被稠密分母稀释。下界见证可以不同，只能取最大值，不能宣称来自同一个最坏源。

为什么这次真的是全域结果

旧稀少后缀下界只在 $\beta\le 1/16$、$z\le M/4$ 的有限域成立，并含截断项

$$\frac{c}{z}\ln\left(1+\frac{1}{8}min\{z/t,M/z\}\right).$$

TR001 没有把它直接外推。高 β 时，$W\le 1/Q+2/\sqrt{M}$；$z>M/4$ 或 $z>M^{3/4}$ 时，$W\le 5/\sqrt{M}$。剩余域才调用截断下界，用对数比较得到 $W\le 1/Q+24L$，其中 L 是上式去掉常数的量。所有边界等号都有归属。[TR001 第 2 至 3 节]

抽样阶要求两项条件同时满足

令

$$Z_{*}=\sqrt{M}\,[\,1+\ln\left(1+\frac{1}{\sqrt{M}\,\beta_{0}}\right)].$$

达到固定倍数的 $M^{-1/2}$ 风险，阶意义上当且仅当 $Q\gtrsim\sqrt{M}$ **并且** $\kappa Q\gtrsim Z_{*}$。前者不能被大权重抵消。必要性适用于每个固定目标倍数；充分性提供某个明确而保守的大倍数，不保证任意小倍数都可达。[TR001 第 5 节]

巨大权重为什么仍不能击穿网格障碍

旧证明中的独立样本网格常数依赖 κ，因此不足以合成上一页的全域结论。UI001 的新结论是：对固定 D,r，在所有有限实数 $\kappa\ge 1$、$Q\ge 1$ 上，都有

$$R_{IID}\ge \frac{c(D,r)}{Q}.$$

这里译码器仍可以输出任意实数。因此这不是“最终概率也要落在网格上”造成的显然误差，而是量化前的局部正权重比值所能传递的信息受限。

先把真正重的窗口揭示出来

取 Bernoulli 独立样本，未知参数 $p\in[1/4,3/4]$。若历史短于常数倍 Q^2，完整历史的两点检验已经给出所需下界。否则，对每个坐标与每个冻结边界分支，按其公开最大可能权重选出最重的常数倍 Q^2 个窗口，把这些窗口内的符号额外告诉译码器。

这是**仅用于下界的增强实验**，不是给上界程序增加免费端口。选取依据是公开表的最大值，不是样本实现值，也不依赖未知参数。揭示后，实际边界分支被固定，而未揭示位在给定 p 时仍然独立。

有高概率，足够多的重窗口恰好出现其最大权重模式。已知重窗口的分母质量遂控制所有剩余窗口的最大权重。对部分揭示的窗口不能偷用无条件模式概率；证明单独计数它们，再处理完全未揭示窗口。条件 Efron–Stein 方差界因而不再含 κ 因子。[UI001 第 2 至 3 节]

揭示后必须重算后验

若揭示了 N 个位，其中有 u 个 1，原先均匀的参数先验会变成

$$\pi(p\mid B)\propto p^{u}(1-p)^{N-u},\quad p\in[1/4,3/4].$$

不能仍把它当均匀先验。高概率后验集中在长度 $O(1/Q)$ 的区间，且密度不超过 $O(Q)$；边界处的截断模式也被显式处理。

与此同时，条件分子均值与分母均值之比的参数导数至多 $8r$。注意这是“均值之比”，不是“比值的均值”。量化库以高概率落在这条短曲线的 $O(1/Q)$ 管状邻域内，故在该后验区间内只有依赖 D,r 的常数个好消息。

常数个译码值的半径 c/Q 邻域不可能覆盖足够后验质量，遂得到 $c(D,r)/Q$ 风险。极重权重不是被忽略，而是先被揭示并正确支付其后验信息；这正是常数不随 κ 退化的原因。[UI001 第 4 至 5 节]

二符号需要新的概率结构

二符号并不免除弱混合下的对数权重需求。BI001 v2 在平稳实验中构造四状态符号对链，并以一个三状态活跃链承载未知参数。记

$$e_0=max\left(\sqrt{\beta},1/M\right),z=\kappa Q.$$

在 $\beta\le1/256$、$z\le M/4$ 上，已接纳下界为

$$R_{stat}\ge\frac{c}{z}\ln\left(1+\frac{1}{8}min\{z/\left(M\,e_0\right),M/z\}\right).$$

当 $\beta\le M^{-2}$，它恢复平方根网格上的 $\Omega\left(\ln M\right)$ 权重必要性。二符号的正混合截断却是 $\sqrt{\beta}$，不是三符号的 β。[BI001 v2]

活跃后缀不是独立硬币

参考活跃链具有统一的两步公共原子，故可以做几何耦合。这个耦合控制任意位置依赖局部和的方差与参数导数，再进行完整好消息计数。真实源对参考路径的概率具有统一下界，各长度后缀事件互斥，因此可以积分并累加。证明没有在给定末尾后把马尔可夫后缀误当独立样本。

实际待预测的行只有一个活跃末尾状态携带参数。证明只在这个状态计入误差，并保证其参考概率有正常数下界；其他末尾状态的损失被丢弃。源的平稳律依赖参数且隐藏，不能作为公开先验标签交给译码器。

匹配上界来自加权回返而非更快全局混合

BU001 v2 为平稳二符号链证明加权倒数占用界。对角状态的权重 q_s 是真实退出概率，交叉状态取 1。对 $\beta>0$，经支撑内的时间反转、Kac 公式和回返矩估计，得到

$$H_s\le\frac{5}{\sqrt{\beta}\,\Pi_s q_s}.$$

H_s 为支撑内最大平均命中时间；零权重状态在除法前剔除。这不是声称全链谱隙提升为 $\sqrt{\beta}$。把误差按退出概率加权，避免几乎吸收的对角行付出不必要的单位误差。

对**同一个**完整八坐标三元组库程序，BU001 v2 已给出

$$R_{stat}\left(T_{SB}\right)\le min\{1,\frac{2^{17}}{\sqrt{M}}+\frac{3}{Q}+544\,W\left(\kappa Q,M\,e_0\right)\}.$$

零访问与正访问但整个所选块舍入为零的情况都单独收费；不会把不可见计数当作译码输入。当 $\beta<M^{-2}$ 时使用原有无混合占用界；该上界只支持平稳初始化。[BU001 v2 第 1 至 4 节]

二符号平稳联合前沿及字母表差异

BS001 已将上一页的二符号下界与上界、统一独立样本网格下界和完整历史统计下界合成为完整平稳前沿，不增加任何模型端口。与三符号类似的全域比较逐一覆盖截断下界之外的参数域。[BS001 第 1 至 4 节]

主域为固定 $K=2$、$D\ge 8$、$r\ge 3$，以及 $M\ge 64$、整数 $\kappa\ge 1$、二进 $Q\ge 16$。令

$$F_2=max\{M^{-1/2},Q^{-1},W(\kappa Q,M e_0)\},e_0=max(\sqrt{\beta},1/M).$$

在全部合法预算上，$c F_2\le R_{stat}\le min\{1,C F_2\}$；常数仅依赖固定架构。其抽样阶联合条件仍是 $Q\gtrsim\sqrt{M}$ 与 $\kappa Q\gtrsim Z_{*,2}$，其中 $Z_{*,2}$ 把第 2 页 Z_* 中的 β_0 换成 e_0。

同一接口下比较而不是换一个问题

在 $\beta=1/M$、合法 $Q\asymp\sqrt{M}$ 时，二符号的 $M e_0=\sqrt{M}$，所需对数因子保持常数；三符号及以上的 $M\beta_0=1$，对应因子是 $\ln M$ 阶。已接纳合成由此确认：平稳实验中，二符号最小权重为常数阶，而固定三符号及以上为 $\Theta(\ln M)$。该最小可行预算结论均以足够大的固定目标风险倍数为前提。[BS001 第 6 至 7 节]

两边比较必须使用相同的全状态证书、真实末尾损失、固定局部单块接口及足以包含实际上界的维数。对任一固定 $K\ge 3$，可共同取 $D\ge K^3$、$r\ge 3$；但常数仍依赖固定架构，并不对增长字母表或增长维数一致。

最小预算必须区分实数下界与整数程序

在固定平方根网格带内，令

$$f_Q=1+\ln\left(1+\frac{Q}{M e_0}\right).$$

下界允许假想的实数权重预算，因而可以证明每个可行实数预算至少为 $c f_Q$。上界则实际选择整数 $\kappa=\lceil f_Q\rceil\le 2f_Q$，不能把实数预算原封不动当作整数实现。

“最小可行整数预算为 $\Theta(f_Q)$”还要求目标风险倍数足够大，使显式上界确实可行。常数极保守，不能读作数值设计建议，也不能据此承诺任意小的目标倍数。

仍然开放的初始化问题

二符号改进上界依赖平稳时间反转与加权回返。不能从三符号的任意初始化结论自动推导二符号的 $\sqrt{\beta}$ 前沿。后继研究需要检验完整后缀平稳混合能否保存加权估计而不付出过大的烧入损失；这是一条待证明路线，不是已完成结果。

风险改善没有免费减少全部计算费用

实际程序仍是 SB001 的完整三元组库。匹配末尾对的键权重为 κ，其他键权重为 1；不删除任何键。所有坐标先舍入，再选出末尾对对应的块并归一化，全零则回退，最后支付概率单纯形舍入。所选块原质量为

$$\rho=\frac{\kappa J}{M+(\kappa-1)J}.$$

J 与 ρ 只是分析变量。运行时没有精确分母、计数、平稳质量、退出概率或回返时间端口。给定合法预算后程序也不读取 β；按公开类承诺预选预算与在线学习未知参数是两回事。

网格位数和完整算术字长必须分开

令 $n_{prog}=M+3$、$\ell=\lceil \log_2(n_{prog}+K+2)\rceil$、$k=bitlength(\kappa)$。同一程序支付

$$b=64(h+\ell+k+1),T_0=O\left(n_{prog}^2K^6b^2\right),$$

$$S=O\left(n_{prog}^2+n_{prog}K^3b+K^6b+b^2\right).$$

最终网格位数是 h，有效自然分数范围是 $\ln\kappa$，内部完整字长是 b。乘积、保护位、两个局部复制头、全部位置和边的工作、完整库、公开掩码、整数缓存、控制器与地址、离线生成、复制和清零均继续计费。顺序寻址实现与 PURE 展开是分别记账的替代方案，不能从两者各取最低项拼成新费用。[SB001 v2 第 6 节]

阅读顺序与证据定位

先读本指南第 1 至 2 页建立模型与联合阈值，再读第 3 页的新网格下界和第 4 至 5 页二符号结构，最后核对本页资源口径。随后阅读新版英文研究稿的相应章节；英文叙述不替代模块证明和审查。

模块顺序建议为 UI001 完整证明及审查，TR001 全域合成及审查，BI001 v2 与版本差异审查，BU001 v2 与版本差异审查，最后是二符号平稳合成。模型与实现细节回查 BA001、SH001、SB001 v2；任意初始化混合论证回查 AU001。构建源与逐文件内容哈希绑定随指南保留。

前四阶段不是被覆盖的草稿：原第四阶段交付包作为未改动的嵌套快照保留，其中较早关于未解问题的表述应按其自身冻结时间理解。第五阶段新增结论只以本阶段对应版本的接收回执为准，正文保留的旧“候选”标题不改变后来接收的版本身份。

科学冻结为 **2026 年 11 月 2 日 06:05 UTC，北京时间 14:05**，包含 UI001、TR001、BI001 v2、BU001 v2 与 BS001。独立语境 LLM 审查与有限诊断不是形式化验证、外部同行评审、文献新颖性认证或网络实测。本文不声称训练可达、一般深网络下界、总资源最优或实际速度提升。