观测轨迹被改写后还能预测什么

第八阶段研究指南 2026 年 11 月 2 日

1 先确定预测对象

本阶段研究的不是神经网络内部的数值噪声，而是进入任何编码器之前，已经被改写的观测数据。结论是：即使交给预测器全部受损历史并允许任意计算，也有不能通过加深网络消除的统计损失。最后两个符号是否受到保护，会根本改变答案。

原始数据来自未知、齐次的二阶马尔可夫源。字母表大小为固定的 K，观测长度为 $M+2$。转移行 θ_{ab} 表示在最近两个真实符号为 (a,b) 时，下一个符号的概率分布。初始二元组分布未知；另外单列从源自身平稳分布初始化的子问题。这里不是只研究某个方便的二元或独立同分布特例。

攻击者在整条轨迹产生之后，最多替换 k 个已观测符号。受保护模型只允许修改前 M 个位置，最后两个位置完全保持原样。预测器看到整条受损序列，但看不到干净内部序列、修改掩码或攻击随机种子，也不知道真实转移表、初始分布或平稳分布。攻击不能修改未来。

令 Z 为受损序列，$S=(X_{M+1},X_{M+2})$ 为真实末端二元组。预测器输出一个概率向量；损失比较的是实际末端的真实下一步分布，而不是重构整段历史的准确率：

$$E\,TV\big(A(Z),\theta_S\big),TV(p,q)=\frac{1}{2}\sum_{c}|p(c)-q(c)|.$$

攻击是定义在完整观测字串上的离线随机核，不把未知源参数作为输入。最小极大风险先对预测器取下确界，再对合法源和攻击取上确界；上界覆盖每个合法核，下界则对整个参数见证族使用同一个核。预测器可有独立随机性和任意计算。

期望不条件于某个罕见末端、某个访问次数或某次攻击成功，而对源轨迹、攻击与预测器随机性全部平均。因此，下界必须保留罕见事件的概率，不能把有利事件当成免费给定的样本。

本文是第七阶段的聚焦补篇，不替代既有精度与容量长稿。科学快照固定为 2026-11-02 09:22:25.495805 UTC；纳入六个接纳单元及其真实审查记录，旧稿和原证明不改写。

2 类条件与统一结论

把相邻符号组成状态后，二阶源变成 K^2 状态的一阶链。源类要求存在平稳二元组分布 Π，并且两步转移在所有起始状态上满足下式，包括平稳支持以外的状态：

$$P\big((a,b),(b,c)\big)=\theta_{ab}(c),P^2(u,v)\ge\beta\,\Pi(v),0\le\beta\le1.$$

这是全状态小集下界条件，不是只在已经平稳的轨迹上成立的平均混合假设。$\beta=0$ 允许很弱的依赖控制；$\beta=1$ 强迫所有转移行具有同一个符号分布。普通最小极大问题允许使用公开的 K,M,k,β，但这里的上界算法不需要知道 β。

对整数 $M\ge64$、$0\le k\le M$，定义清洁统计尺度与有效截断尺度：

$$s=M^{-1/2},e_K=\begin{cases}\max\{\sqrt{\beta},M^{-1}\}, & K=2,\\ \max\{\beta,M^{-1}\}, & K\ge3.\end{cases}$$

$$F_K(M,k,\beta)=\begin{cases}0, & k=0,\\ \dfrac{k}{M}\left[1+\ln\left(1+\dfrac{1}{k\,e_K}\right)\right], & 1\le k\le M.\end{cases}$$

六单元综合后，受保护末端模型的平稳初始化与任意初始化风险，具有相同的固定字母表阶：

$$R_{stat}\asymp_K R_{all}\asymp_K \min\{1,\max\{s,F_K\}\}.$$

这里的比较常数可以依赖固定 K，不能读成随字母表增长仍尖锐的结论。$k=0$ 单独定义为零扰动项，不能把零代入含 $1/k$ 的表达式。风险不超过一，所以公式保留上截断。

三符号及以上由 SC002 给出全参数匹配；二元上界来自 SC003，匹配下界后来由 BT002 补齐。SC003 原文中“移动混合参数下界尚未闭合”的表述是该单元形成时的真实历史，不应删除；最终闭合依赖新增 BT002，而不是重新解释旧证明。

3 为什么完整观测仍有不可消除的损失

先看较容易理解的三符号机制。用一个等待符号和两个活动符号构造合法齐次源：多数时间等待，偶尔进入含未知参数 p 的活动区。活动后缀长度为 j 的各事件互不相交，单个事件的概率约为 $1/M$。平稳版本允许返回等待区，且未来返回概率必须保留在真实预测目标中，不能因过去没有返回而删除。

在给定后缀事件后，活动符号相当于独立伯努利样本。攻击只处理可编辑的前 $j-2$ 个活动符号，保留最后两个。设其中有 n 个一，把总数向下舍入到 $b=k+1$ 的倍数，并均匀选择哪些一留下：

$$r=b\lfloor n/b\rfloor,0\le n-r\le k.$$

这是“均匀删除一符号”的替换规则：删除是把一改成零，不缩短轨迹。若输出排列 z 有 r 个一，则给定原始计数 n，得到这个具体排列的概率为

$$\frac{\binom{\ell-r}{n-r}}{\binom{\ell}{n}\binom{n}{r}}=\frac{1}{\binom{\ell}{r}},\ell=j-2.$$

因此，给定粗计数 r 后，输出的完整排列与未知参数无关。排列不是被预测器“丢弃”了，而是攻击使它不再携带额外参数信息。整个受损字串可由粗计数与受保护末端标签，经一个参数无关通道生成。

末端两比特不能忽略。它们有四种标签，必须计入消息数；不能在看见末端后仍声称参数先验均匀。完整消息数至多为

$$D_j=4\left(\lfloor\frac{j-2}{k+1}\rfloor+1\right).$$

均匀参数先验下，有限消息估计的绝对误差至少为区间长度除以 $4D_j$。对同一个先验、同一个攻击核，在所有后缀事件上累加，便出现调和和与对数项。三符号机制无需人为加入 $j\le k^2$ 的集中截断。即使预测器知道攻击核且拥有全部受损历史，以上信息损失仍然存在。

4 二元困难在哪里以及怎样跨过它

二元源没有第三个专用等待符号可供直接照搬。其活动参考链由长度二的循环 01 和长度三的循环 101 组成。循环选择虽可由独立硬币产生，但固定物理时间下的符号轨迹不是固定位置的独立硬币样本；循环时长和排列也可能携带参数信息。

BT001 先证明了一条真正的失败路线。设短循环数为 s_c、长循环数为二，总长度 $t=2s_c+6$。把它运输到全为短循环的唯一目标字串，其最小平均汉明距离恰好是

$$\frac{2s_c}{3}+3=\frac{t}{3}+1.$$

所以，“所有计数组之间只改变少量计数便只需常数次编辑”是错的。另一种廉价局部合并虽然平均改动不大，却把目标排列分布偏向某些间隙形状；它不能提供需要的参数无关均匀输出。有限线性规划数值仅是诊断，不能修补这个边际分布错误。

BT002 没有解决 BT001 更强的内部计数相邻运输 $O(1)$ 猜想。它改换目标：把固定循环计数的均匀分布运输到由公开网格参数指定、终点固定为 01 的参考链桥分布。利用有限状态耦合、熵不等式与有限运输对偶，得到较弱但足够的平均代价：

$$W_1\left(U_{s_c,l},\nu^{A}_{q,t}\right)\le 1024\sqrt{t\ln(t+1)}+326\,t\,|\hat{p}-q|.$$

这里 $\hat{p}=l/(s_c+l)$ 是从可见循环计数得到的频率，不是真实源参数。耦合表只依赖公开长度、预算与计数，可用有限有理运输问题定义；不要求其计算高效。合适网格下，平均代价远小于 k，但仍需处理超预算的随机样本。

实际核先抽取运输输出，只有原字串到最终输出的汉明距离不超过 k 才采用，否则原样返回。这样每条轨迹都严格守预算。截断失败概率是常数级小量，不能直接从趋零的风险下界中减去；证明先以独立辅助种子建立有限候选预测值的小球概率界，再从成功概率中扣除坏概率，最后乘误差半径。

该路线确有长度上限 $t\lesssim k^2/\ln(k+2)$。BT002 的第二组件用有限域标量不等式，将截短调和和与清洁风险、k/M 两个独立下界合并，恢复完整最终阶。闭合的是统计率，不是被截断的运输定理。

5 上界怎样从受损历史计算

三符号及以上无需识别攻击。统计受损字串的所有三元组，并在可见的末端行上做加一平滑即可。一次符号替换最多影响三个三元组，每个改变使全直方图的绝对差总和最多增加二。因此

$$\| C' - C \|_1 \le 6k, TV(q', q) \le min\{1, \frac{6k}{J+K}\}.$$

这里 C, J, q 是干净轨迹的计数、实际末端行访问次数及加一向量，仅用于证明；算法只读受损计数。保护末端确保干净与受损计数选的是同一行。SC002 将清洁风险界、实际末端占用界与精确后缀混合分解结合，避免粗糙的额外烧入误差；算法本身不需要 k 或 β。

二元情形需要不同的、知道预算但不知道混合参数的下包络估计。对每一行固定一个指定后继：$00, 01$ 指向一，$10, 11$ 指向零，即取该行第一个比特的补。方向不由未知概率或经验少数类决定。

令 C'_{exit} 是受损历史中该指定后继的次数，J' 是受损末端行总次数。正预算时输出该坐标概率及其补概率：

$$\hat{q} = \frac{(C'_{exit} - 6k)_+}{J' + 6k + 2}, \hat{q}_{other} = 1 - \hat{q}.$$

分子先扣掉最坏污染量，分母再留安全余量，防止攻击凭空制造的退出计数贡献假概率质量。对干净计数 C, J，路径上有 $0 \le \hat{q} \le C/(J+2)$。真实指定概率 q 只在分析中作为占用权重出现，绝不是算法需要知道的输入。

当 $k = 0$，算法另用普通二元加一平滑；不能把正预算公式设为零预算并称其为加一。二元平方根混合截断来自加权占用结构，不表示整条二元链在 $1/\sqrt{\beta}$ 时间内全局混合。

SC003 已证明一个保守的有限有理实现：保留输入、重新扫描三元组，用两个计数器输出共享分母的两坐标，位运算成本 $O(M \log(M+2))$，含输入输出的同时存活位数 $O(M + \log(M+2))$。它没有证明 Transformer 深度、注意力预算、训练可达性或最优计算复杂度。

6 如果末端也能被修改

EP001 只改变一个权限：最后两个观测符号也允许被编辑。其他条件保持不变，特别是目标仍然是原始真实末端的下一步分布，而不是受损末端对应的转移行。对所有固定 $K \ge 2$，两种初始化的风险阶变为

$$R_{end} \asymp_K min\{1, max\{M^{-1/2}, \frac{k}{M}, (1-\beta)1_{\{k \ge 1\}}\}\}.$$

原因不是参数表难估计，而是被擦掉的实际末端本身无法恢复。取一个对称二元一阶源，其两行有适度差别；把最后一个观测比特统一设为零。预测器即使知道完整源规律，并看到此前所有干净符号，仍不知道被抹去的末位是哪一个，其真实下一步分布仍有两种可能。

令 $\delta = 1-\beta$，取 $\alpha = min\{\delta/2, 1/4\}$，两行的“一”概率为 $1/2 \pm \alpha$。给定此前历史后，最优绝对损失仍为

$$\left(\frac{1}{2} - \alpha\right) 2\alpha \ge \frac{\delta}{8}.$$

一次编辑就能产生这个下界，故对任意固定 $\beta < 1$，正预算下风险不能趋零。该攻击对所有输入固定定义，不使用隐藏参数。编辑掩码仍不提供；对这个具体擦除规则，若额外暴露“是否真的替换”的指示，可能泄露原末位，因而不能擅自把可见掩码视作等价问题。

上界也解释了 β 接近一时为何例外。把全状态两步下界对第二坐标求和，可得所有转移行都接近同一个符号边际分布 π：

$$\theta_u(c) \ge \beta \pi(c), TV(\theta_u, \pi) \le 1-\beta.$$

正预算时直接汇总受损的第 3 至第 $M+2$ 个符号。干净经验频率减去逐时条件均值是鞅平均，二阶矩给出 $M^{-1/2}$ 误差；两次向共同分布比较花费 $2(1-\beta)$，编辑改变频率至多 k/M。零预算仍单独使用清洁加一规则，避免不必要的偏差项。这不要求恢复真实末端，也不把未知 π 提供给算法。

7 预算尺度与同条件比较

如果希望受损风险仍处于清洁统计阶，保护末端模型的要求是扰动项不超过常数倍 $M^{-1/2}$。将统一剖面反解，可用下列统计阶预算尺度表示：

$$k_* \asymp \frac{\sqrt{M}}{1+\ln\left(1+\dfrac{1}{e_K\sqrt{M}}\right)}.$$

这是已证风险公式的代数推论，不是新的攻击模型定理。充分与必要方向允许不同的比较常数；也不应把它解释成精确整数预算界或实用算法的安全阈值。

在 $\beta=0$ 时，二元和更大固定字母表都给出 $k_* \asymp \sqrt{M}/\log M$。而在 $\beta=1/M$ 时，二元有效截断为 $1/\sqrt{M}$，预算尺度为 $\sqrt{M}$；三符号及以上有效截断仍为 $1/M$，预算尺度保留对数损失。这是字母表结构产生的差别，不是把某个常数隐藏在符号内。

若末端不受保护且预算为正，要保持清洁统计阶，就同时需要

$$1-\beta=O_K\left(M^{-1/2}\right), k=O_K\left(\sqrt{M}\right).$$

在固定非独立源类中，仅减小内部量化误差或增加历史长度无法消除末端信息丢失。反过来，保护末端不是无关紧要的技术便利：它决定预测器是否知道自己正在回答哪个真实条件分布。

与第七阶段比较时，应把故障位置分清。内部切口噪声或量化研究的是特定编码之后的信息；源符号替换研究的是任何编码之前的观测损坏。前一种下界不自动适用于拥有完整受损历史的预测器，后一种下界却约束所有只读取该受损历史的下游结构。

本阶段上界是完整历史计数基线。它不说明某个受限网络已经实现相同风险，也不允许给保护器免费的干净副本、可信末端标签以外的额外端口或免费的高精度存储。比较网络和计数器时，必须对齐输入、攻击权限、末端保护、随机种子可见性及全部资源成本。

8 结论与证据如何对应

本阶段的科学结论由六个接纳单元组成，而不是六个未经区分的“完成”标签。SC001 和 BT002 各包含两份承重证明；完整审查与接纳回执绑定具体字节版本。

SC001 给出零混合下三符号及以上的完整受损历史定律。主证明建立精确排列擦除与任意初始化界；独立的平稳推论构造可返回的平稳见证。二者共同说明对数损失不是瞬态初始化的人为产物。

SC002 扩展到所有混合参数，给出固定三符号及以上、两种初始化的匹配阶。承重内容包括全状态证书、真实未来返回质量、精确排列信息核算，以及末端占用的后缀混合上界。

SC003 证明二元预算已知、混合参数未知的有理上界，并提供清洁风险与线性污染下界。它独自不证明增长对数项的匹配下界。使用的是完整新审查，而不是较早仅检查代数和方向的局部审查。

BT001 接纳的是边界运输反例、局部廉价合并的分布偏差、修改后的平稳见证与明确带假设的归约。强内部运输前提仍未证明；小型浮点线性规划没有把它升级成定理。

BT002 的主证明建立熵到公开桥分布的弱运输、严格预算截断及共同先验小球下界；标量组件处理截短求和、空和与有限边界。与 SC003 结合后闭合二元剖面，不回写 BT001 的未决身份。

EP001 在明确改变末端权限后证明新的风险阶，依靠全状态边际推论、汇总鞅上界和已知源下的单末位擦除下界。它不是把受损末端替代真实目标。

这些新证明仍继承清洁统计与占用接口：R011 的 ORIGINAL 加一规则及清洁下界；IU001 的平稳末端占用；AU001 的任意起点与精确后缀混合；BIF001 和 BAI003 修订版的二元加权占用。此处不是重新形式化验证全部历史依赖。来源绑定另记可重建路径、SHA-256、接纳回执和冻结记录，避免正文中的历史候选标题被误认成最终接纳状态。

9 证据边界与真正开放的问题

有限诊断检查了组合恒等式、全部状态证书、严格编辑预算、若干小轨迹枚举和标量常数。精确有理检查支持所测实例；浮点运输优化只支持有限数值现象。无论检查次数多大，都不能替代对所有长度、预算和源的数学证明。

本阶段每个新单元都经过独立 LLM 数学审查并由根任务接纳。该身份应准确保留：它不是形式验证、外部同行评审或期刊接受。审查中真实发现的修订也保留，例如 BT001 对辅助种子反向分解的澄清，以及 BT002 标量截断分母由四到八的接口校正。通过最终检查不意味着历史上从未出现问题。

已有文献筛查是有范围的初步比较，不是穷尽的新颖性审计。source_corruption_screen.md 对有限马尔可夫链稳健参数推断只阅读了摘要、引言与污染定义相关讨论；对动态转移扰动和一般对抗均值估计只阅读摘要。它们分别说明既有研究对象与这里的固定预算观测字串替换存在差异，不足以排除更接近的先行工作，也未核对全部证明。

因而目前不能声称这组阶数或证明机制已获外部新颖性确认。本文不将既有文献的名称当作未读定理的权威背书，也不从“有限筛查未发现相同结果”推导“此前无人研究”。原筛查文件保留准确链接和逐项阅读范围，便于以后继续核对。

后续有意义的问题仍包括：增长字母表的尖锐常数和阶；不知道预算时的二元自适应；严格在线攻击与离线攻击的差别；可见掩码或可见攻击种子的独立统计模型；具有明确深宽精度成本的网络实现；训练过程能否达到已证构造；以及 BT001 强内部运输猜想本身。

这些问题不能通过复制本阶段率公式自动闭合。尤其，有限有理预测算法的存在不证明可训练性，运输耦合的有限存在不证明高效采样，某个下界攻击可在最后一步实施也不证明整个在线最小极大问题与离线等价。

读者应带走的结论是具体而有限的：在固定字母表、未知齐次二阶源、完整受损历史与隐藏修改信息的实验中，保护真实末端时已经得到两种初始化的匹配统计阶；取消保护则出现新的末端不确定性项。完整观测、任意计算和正确的目标定义三者，缺一不可混淆。