有限精度注意力表示与统计风险

第三阶段研究指南 2026 年 11 月 2 日

这一阶段回答的是：前一阶段在一个固定统计量库上得到的精度障碍，能否推广到可选择的编码器；如果在量化之前改变表示，又能以什么代价越过障碍？已接纳的结果给出两条相接的路线。固定局部范围、固定维数和有界权重的编码器族，在声明的容量条件下仍具有相同的完整风险前沿；允许完整三元组库和缓慢增长的权重比，则可在半对数网格位数上达到抽样误差阶。[BF001；CF001；SB001]

这里的“代价”不是单一位数：最终网格、有效分数范围、完整算术字、公开数据、工作区和计算深度必须分开。有限算术证书已补上特定因果子类的实现缺口，但并没有证明总费用下降、训练可达或一般 Transformer 最优。

同一个预测问题与信息边界

观察未知齐次二阶源的 $X_1,\dots,X_{M+2}$，预测实际末尾符号对 $Y_M=(X_{M+1},X_{M+2})$ 的下一符号分布。损失是同一轨迹上的无条件期望总变差。符号对核满足全状态两步条件

$$P^2(s,t)\ge\beta\,\Pi(t),\beta\in[0,1].$$

Π 是未知平稳分布；条件包括平稳支撑外的起点，允许零转移和非可逆性。共同主域为固定 $K\ge3$、$M\ge64$、$Q=2^h$、整数 $h\ge4$。增长权重构造的部分上界也允许 $K=2$，但这里不宣称二符号的匹配对数下界。

在每一种声明的表示中，译码器只读**完整量化库、允许的有限边界符号和公开参数**。它可以任意计算、随机化并输出实数概率，但不能重读历史、干净的分子分母或其他位置的输出。下界针对整个消息，而不只是某个坏坐标。

保留下来的统一前沿

记 $\beta_0=max(\beta,1/M)$，则

$$W=\frac{1+\ln\left(1+Q/(M\beta_0)\right)}{Q},H=max\left(M^{-1/2},W\right).$$

FR001 已在原固定库上证明风险为 H 阶。本阶段 BF001 与 CF001 分别在其声明的编码器族中证明

$$c_{arch}H\le R_{stat}\le R_{all}\le min\left(1,C_KH\right).$$

常数不依赖 M,β,Q，但依赖固定架构或 K。当 $\beta=O(1/M)$ 时，达到 $M^{-1/2}$ 风险需要网格位数 $1/2\log_2M+\log_2\ln M+O(1)$；这不是所有表示都必须支付的位数。

从固定统计量库到有界局部编码器族

BA001 不再固定原来的四个统计头。它允许为每个位置和标量坐标选择任意源无关的局部表：键使用最后 r 个符号，查询由有限边界符号 S 决定，全部 M 个键都参与。每个输出为

$$B_d=\frac{\sum_i w_{di}v_{di}}{\sum_i w_{di}},Z_d=\frac{\lfloor QB_d\rfloor}{Q},0<a\le w_{di}\le b<\infty,|v_{di}|\le 1.$$

D 是保留的**标量坐标数**，不是物理注意力头数；多个坐标可共享分母。$0<a\le b<\infty$，D,r,a,b 均不随 M,Q 增长。位置表可依赖公开参数甚至已知类承诺 β，但不能包含未知源的信息。查询选择的硬掩码、非局部预计算值和额外精确历史统计不在这个族中。

仅有小敏感度还不够

改变少量局部项只造成小变化，这是标准的稠密注意力稀释机制。但任意实数译码器可能读出极小差异；小直径的 D 维盒子也通常有 D 次方数量的网格点。因此，不能直接把敏感度界称作信息丢失定理。

证明使用一个真正平稳的三符号源族：长等待段后出现随机长度 j 的活跃段，所有长度共享同一未知参数先验。先冻结每个可能的边界查询，再对未条件化的独立活跃符号做集中分析；最后同时覆盖各分支并选回真实分支。这样避免了“给定末尾查询后仍然独立”的错误。

在有效长度范围内，整个量化消息接近有限条短参数曲线，波动厚度为 $O(\sqrt{j}/M)$。曲线覆盖给出

$$\#\{\text{good messages}\}\le A(1+Qj/M).$$

好事件可以依赖未知参数，容纳所有好消息的集合却不能依赖它。再将有限消息估计误差对这些活跃长度作调和累加，得到

$$R\ge\frac{c}{Q}\ln\left(1+\frac{1}{8}min\{Q/(M\beta_0),M/Q\}\right),\beta\le 1/16.$$

另有全域 c'/Q 下界和完整历史也无法避免的 $M^{-1/2}$ 下界。它们取最大值，不把不同见证的风险相加。BF001 保留上式的有限域截断，再分区比较，才完成全部合法 Q,β 的 H 前沿。[BA001 第 1 至 8 节；BF001 第 2 节]

匹配上界必须核对实际有限输出

当 $D\ge 9K+1$、$r\ge 3$、$0<a\le 1$、$b\ge 6$ 时，原有限 SRC 库确属该族：实际整数指数求值器产生的权重在 $[1,6]$，不是用理想指数替换后的近似。四个统计头合计 $9K+1$ 个标量，另有两个局部复制头。接上原 NB002 译码器便给出上界。因此这里是**优化编码器之后的族极小极大结论**，不是声称每一个合法编码器都好。[BF001 第 3 节]

因果多层表示需要不同的影响界

CA001 允许固定深度中递归形成的非局部中间特征。每层因果行对前缀进行稠密 softmax 汇聚，分数、值和原始部件的 Lipschitz 常数统一有界；也允许固定密度的公开因果掩码。深度、宽度、头数和最终坐标数固定。这与 BA001 的任意局部表模型并非简单的包含关系。

对比两个输入时，必须同时计入值变化和注意力权重变化。以 δ_t 表示位置误差，可得

$$\delta'_t \le a\,\delta_t + \frac{b}{t}\sum_{i\le t}\delta_i.$$

三角平均矩阵的幂由调和和控制。若 $T = M + 3$ 为合成末端位置、层数为 L，第 i 个历史符号的替换影响具有包络

$$d_i \le \frac{C}{T}\bigl(1+\ln(T/i)\bigr)^{L-1}, \sum_{i<T} d_i^2 \le \frac{C'}{M}.$$

晚段位置仍有 $O(1/M)$ 影响；早段可多出对数因子，但平方和可控。这恰好支持活跃后缀与全独立历史的集中界，进而恢复完整消息曲线计数。[CA001 第 2 至 5 节]

一个必须保留的真实反例

令两层都为零分数的因果均匀平均，记 $A_{ti} = 1\{i \le t\}/t$。改变第一个输入符号时，末端变化恰为

$$(A^2)_{T1} = \frac{H_T}{T}, H_T = \sum_{u=1}^{T}\frac{1}{u}.$$

因此“所有位置一律为 $O(1/T)$”的更强引理是假的，即使只有一个头、值和激活均有界。CA001 使用的是修正后的对数包络和平方和，**这个反例并未推翻已接纳的 CA001 定理**。

分支内因果不等于时间上的因果

CA001 的扩大边界分支模型允许历史参数依赖完整 S。若 $S = X_N$，并把每个历史初始状态设为 S，注意力边仍然因果，但第一位置已经知道末尾符号。正确称呼是“每个冻结分支内具有因果注意力”，不能统称普通端到端因果网络。

下界仍成立：它对每个冻结分支的**所有形式历史**证明集中性，再把有限分支标签计入消息。CF001 的真正时间因果子类进一步限定：历史表、参数和掩码不能依赖未来边界；S 只进入追加末端的初始查询。该子类继承下界，而且有经过单独核对的构造性上界。[CA001 边界因果范围说明；CF001 第 1、3 节]

CA001 本身首先是理想实数网络加最终网格的定理。中间舍入不连续，不能声称“每层也舍入”后原 Lipschitz 推导自动有效；下一页的有限算术证书补上的正是这个缺口。

有限算术证书如何补上实现缺口

FA001 针对明确的有限数据子类：仿射 QKV、点积分数、仿射与 ReLU 更新、固定深宽、有限二进制有理参数，以及有界理想可达状态。它不包括未提供求值器的任意非线性映射；本证书也不包含层归一化，正的稳定常数并不能替代平方根与除法的误差审计。

取内部尺度 $R_P=2^P$，每个数用有符号整数表示。负数也向负无穷舍入，不截成零；乘积和整行累加保留完整精度，只在规定位置作整除。对分数加同一正移位，记其整数编码为 U_s。取 $J=P+j_0$，其中 j_0 为可计算架构常数，使用递推

$$T_0=R_P,T_j=\left\lfloor \frac{T_{j-1}U_s}{jR_P} \right\rfloor,W_i=\sum_{j=0}^{J}T_j.$$

移位在理想 softmax 比值中消去，常数项确保 $W_i\ge R_P$。没有执行实数指数或对数。若整数值为 V_i，归一化严格为

$$Z=\sum_i W_i,N=\sum_i W_iV_i,O=\left\lfloor N/Z \right\rfloor,o=O/R_P.$$

这里不能再多除一次 R_P。由于 $Z\ge mR_P$，m 个键带来的分子与分母误差一同消去，误差不随键数线性增长；有符号相消也不破坏分母下界。

逐层估计在理想状态周围的固定邻域进行，再用自洽归纳保证有限状态一直留在该邻域。可计算的架构常数使

$$P=4h+C_{arch},\left\| F_{fin}-F_{ideal} \right\|_\infty\le 2^{-h}=1/Q.$$

这是从整数原语证明的统一误差证书，不是把所需误差当作假设。最终网格标签可能改变，证明只需扩大消息管状邻域，不要求与理想标签完全相同。[FA001 第 2 至 5 节]

CF001 如何得到完整风险前沿

CF001 显式构造一个半径三的因果局部输入、四个统计头、状态宽度 $12K+4$ 的理想原型；公开键集合密度至少 $1/3$，只有末端查询读取边界 S。有限编译器以目标 $h+3$ 运行，得到 $1/(8Q)$ 误差。有限对数系数对真实对数头的误差另付 $1/(8Q)$，最终粗网格再付小于 $1/Q$，合计

$$\text{master error}<\frac{5}{4Q}<\frac{2}{Q}.$$

还须证明主值确实位于闭区间 $[0,1]$ 的网格上。正权重和精确位值保证了这一点。随后 NB002 的确定性后缀分析保留行频率误差 $76/Q$、汇总误差 $6/Q$ 和拒绝包含关系，才可转移原风险上界。这是新求值前缀加旧后缀，不是声称原程序、网格标签或分支决定完全不变。[CF001 第 3 至 4 节]

改变量化之前的表示可以越过障碍

固定权重族的下界不禁止改变权重动态范围。GW001 先展示一条完整计费的逃逸路线：两个局部复制头加一个 K 维后继值头，按两个上下文符号的匹配数选择实际整数权重

$$\{1, M, M^2\}.$$

主方案的权重比是 M^2，有效自然分数范围为 $2\ln M$。整数码只有三个取值，不意味着有效分数有界。它改用了整数权重缓存，不再是旧有限指数求值器；不执行对数或指数，却依然支付权重及累加器的位宽。[GW001 第 1 至 4 节]

若末尾上下文此前出现 $J \ge 1$ 次，非匹配键在后继值坐标中造成的污染至多为 $1/J$。对真实末尾的占用次数积分后，半对数网格已足够达到 $M^{-1/2}$ 风险阶。可选的更强全路径近似使用 $\{1, MQ, (MQ)^2\}$，其权重比为 M^2Q^2；不能把这个更大比值误记成主方案的费用。

完整三元组库减少污染而不删除键

SB001 换用完整 K^3 维三元组 one-hot 值。查询和键为 K^2 维符号对 one-hot；相同对的实际权重为整数 κ，其他键为 1。全部键仍参与，不存在查询硬掩码。

若 C_c 为末尾对对应的后继计数，所选块在量化前为

$$B_c = \frac{\kappa C_c}{M + (\kappa - 1)J}, r = \sum_c B_c = \frac{\kappa J}{M + (\kappa - 1)J}.$$

关键区别是非匹配三元组去了其他坐标。它们稀释所选块的总质量，却不污染该块内部的后继组成。译码器在完整库逐坐标向下舍入后，选出末尾对的 K 个坐标再归一化；若全为零则返回预定概率向量。它看不到 J, C_c, r 或精确分母。

先看不放大的强标准基线

当 $\kappa = 1$ 时，这就是均匀注意力保留完整三元组直方图，再选择条件块。它已经是强而标准的表示基线，不是新发明。仅在网格后归一化无法复活已落到零的稀少块；$\kappa > 1$ 的作用是在网格前提高这部分质量。

包括全零舍入分支在内，归一化误差满足

$$TV(\hat{p}, C/J) \le min(1, K/(Qr)), J \ge 1.$$

这条标准条件化不等式说明为什么放大有效，也说明最终要证明的是**真实末尾占用次数下的平均损失**，不是每条历史都能精确恢复计数。K^3 库与旧 $9K+1$ 库的特征成本不同，固定 K 的风险比较不等于相同的随 K 资源费用。[SB001 第 2 至 4 节]

双对数有效分数范围的上下界

令 $\Psi(x)=x(1+\ln(1/x))$ 在 $0<x<1$，并在 0 取 0、在 $x\ge 1$ 取 1。任意初始化的末尾访问数满足

$$Pr(J<w)\le min\left(1,K^4 w/(M+1)\right),w\in\mathbb{N},w\ge 1.$$

这由逐状态“前 w 次访问”计数和后缀比较得到，不要求末尾查询独立于历史。对上一页的确定性误差积分，令 $D_K=K^5(K+1)$，SB001 给出

$$R\le min\left(1,2^{13}H_{stat}+\Psi\left(\frac{K^5}{M+1}\right)+\Psi\left(\frac{D_K}{\kappa Q}\right)+\frac{2K-1}{Q}\right).$$

$H_{stat}\le K^{5/2}/\sqrt{M+1}$ 是原 add-one 预测器的统计尺度，不是把另一自适应预测器的最优尺度直接移植过来。所有常数都可能很保守。

不读取混合参数的充分选择

只用整数位长即可选取

$$\ell=bitlength(M+1),\kappa=\ell,h=max(4,\lceil \ell/2\rceil).$$

此时 $\sqrt{M+1}\le Q\le 2\sqrt{M+1}$，风险为 $O_K(M^{-1/2})$，同时

$$\ln\kappa=\ln\ln(M+1)+O(1).$$

因此，完整三元组库把 GW001 的充分 $O(\ln M)$ 有效范围降到 $O(\ln\ln M)$，最终网格仍只需半对数位数。这里的有效范围是最大最小实际权重比的自然对数，不是存储一个分数的总位数。[SB001 第 1、4 节]

匹配的是范围的阶而不是权重比

固定 D,r，将 BA001 单个全局汇总块族的权重范围扩为 $[1,\kappa]$。显式常数代价至多为 κ^{D+1} 因子。在 $\beta=0$、$Q\asymp\sqrt{M}$ 时，有限定理因而给出最终的渐近下界

$$R\ge\frac{c\ln M}{\kappa^{D+1}\sqrt{M}},\ln\kappa\ge\frac{\ln\ln M}{D+1}-O(1)$$

其中第二式以达到某个固定倍数的抽样风险为前提。比较族允许至多 D 个标量，包含此构造需 $D\ge K^3$、$r\ge 3$。所以匹配的是有效范围的 $\Theta(\ln\ln M)$ **阶**，不是精确的 κ 阈值，也不是任意深网络的下界。

可选混合细化令 $f=1+\ln\left(1+Q/(M\beta_0)\right)$。同一受限族在平方根网格上有 $1+\text{range}=\Theta(1+\ln f)$，充分性对应足够大的固定目标风险倍数。根据已知 β 类承诺选预算不是学习未知 β；其额外输入与预算计算也不能免费。[SB001 第 5、7 节]

哪些费用没有随着网格位数一起下降

最终网格、有效分数范围和内部算术是不同资源。CA001 的绝对实数网格本身甚至不意味着有限位存储；只有另给固定输出范围，才有每坐标 $h+O(1)$ 位。闭区间 $[0,1]$ 含端点 1，其整数分子可达 Q，需要 $h+1$ 个无符号位。

资源	本阶段可用的明确界或规则
最终网格	$Q=2^h$；SB001 用半对数 h 达到固定 K 抽样阶
有效分数范围	SB001 为 $\ln \kappa$；不等于数值码位长或全部算术精度
FA001 小数精度	$P=4h+C_{arch}$；CF001 使用目标 $h+3$
完整数值工作字	$w=O_{arch}(P+\log n+\log(P+1))$，另计更大公开数组地址
转换后公开记录	紧凑格式每项 $P+O_{arch}(1)$ 位；原始描述及转换另收费
掩码与工作区	掩码、参数表与输出独立收费，滚动数组不能替代总峰值

两项真正的账本修正

扩大边界端口需要额外获取。 BF001 的原六个头不能免费给出任意首尾 r 窗口。完整物化该端口时可增加至多 $2r$ 个已计费的单键复制头，总数至多 $6+2r$；新增掩码、所有位置的工作、复制与保留存储都要支付。地址宽度也改用

$$p_{aug}=p+\lceil \log_2(D+r+K+2)\rceil,$$

其中 $p=4h+4\lceil \log_2(M+K+4)\rceil+64$ 是原字长参数，原完整乘积与保护位最多 $128p$ 位，新增部分可用 $128p_{aug}$。不能把原始字长或头数原封不动套给扩大接口。[BF001 第 4 节]

公开记录填充改变存储账。 FA001 的紧凑记录按顺序排列、位置隐含，故 U 项转换数据占 $O_{arch}(UP)$。若每项都填充为完整工作字，就应改收 $O_{arch}(Uw)$ 的存储、写入、清零与峰值，而不能仍引用较小账本。工作数组始终保留完整乘积和累加保护位。[FA001 第 6 节]

固定理想深度不等于固定有限电路深度

有限多带求值器支付真实扫描、回卷、控制、参数转换、全部位置与边的计算。SB001 还支付 K^3 特征与全库、K^2 匹配、稠密零系数、局部复制和整数缓存。纯布尔或 ReLU 展开另付门、保持、接线和稠密参数；不能混取两种实现的最低费用。峰值取每阶段同时存活对象之和再取最大值，不是单独滚动工作区。

上述改正是具体的范围与费用修正，不应叙述成“所有接纳定理都曾失败”。它们保留数学风险结论，同时阻止资源结论被夸大。当前没有总字长减半、实际速度优势或网络训练成功的证据。

文献定位与可核对的阅读路线

加权库存与直方图是已有构造。 Behrens、Biggio、Zdeborová 的 Counting in Small Transformers 第 4.1.2 节及附录 B.3 给出正交库存和两级权重。其选中质量已具有 $ek/(L+(e-1)k)$ 形式，并讨论反演；这里按上下文分块归一化是这一表示思路的自然延伸，不是新计数机制。该文主要采用无限精度计算，未给出本研究的末尾预测风险与网格前沿。

稀释机制不能替代完整消息论证。 Hahn 的 TACL 2020 论文 与 2021 作者补充 是有界稠密注意力敏感度的重要前例；补充明确加入权重变化项。Chiang 与 Cholak 的 ACL 2022 论文 则说明极小差异仍可保留精确认别信息，并区分零稳定项归一化和随长度增长的分数。这里的有限网格、任意译码器和完整联合消息必须另行证明。

双对数精度不等于双对数分数范围。 Merrill 与 Sabharwal 的 2023 版本 第 3 节讨论存储归一化权重时的浮点下溢；那是指数表示范围问题，不是 SB001 的 $\ln \kappa$。本阶段的实质在于量化截面、实际末尾占用积分和增长权重下仍显式受控的族下界，而不是对“对数”字样作新颖性认领。

完整比较见包内 prior_art/loglog_score_budget_comparison.md 与 prior_art/bounded_attention_family_comparison.md。它们记录有界范围的一手来源检索；“未找到同设置定理”不等于新颖性认证。

科学冻结对应的版本

单元与版本	在论证中的职责
FR001 v1	前阶段固定完整库的全部精度风险基准
BA001 v1 与 BF001 v3	有界局部族的完整消息下界与匹配前沿
CA001 v3 及边界因果说明 v1	理想固定深度影响界与准确因果范围
FA001 v3 与 CF001 v1	有限算术误差证书与时间因果子类前沿
GW001 v3	增长整数权重的完整计费逃逸方案
SB001 v2	完整三元组库与双对数有效范围阶

科学冻结为 **2026-11-02 04:45:00 UTC，北京时间 12:45**，不收录之后的新主张。表内定理版本均已在此前接纳，后续匹配回执解释旧正文的候选状态。独立语境 LLM 审查和有限诊断不是形式化验证、外部同行评审或性能测量；边界因果说明只是范围澄清。

先读第 1、5、6 页把握结论，再读第 2 至 4 页证明接口与第 7 页资源。完整细节见模块化证明及审查；英文研究稿提供连贯叙述，不替代档案。下一步可收紧 κ 依赖或研究新架构族；现有单块范围阶结论没有解决这些问题。